第6卷 第4期 计 量 经 济 学 报 Vol. 6, No. 4
2026年7月 China Journal of Econometrics Jul., 2026

doi: 10.12012/CJoE2025-0645

AI 质性访谈与自动化主题编码：以三个政策相关话题为例

董 璐 [1], 黄凌波 [2], 鲁琳琳 [1]

(1. 南方科技大学商学院, 深圳 518055; 2. 山东大学经济研究院, 济南 250100)

摘 要 随着大语言模型 (LLM) 的快速发展, 质性访谈在经济学研究中的规模化应用成为可能. 本文介绍了一种基于多代理 LLM 的半结构化质性访谈方法, 并据此构建了一套完整的工作流程: 由 AI 作为访谈员开展标准化且可追问的半结构化访谈, 随后由 LLM 配合人工审查从访谈文本中提取主题并完成自动化主题编码, 实现从访谈到编码的统一流程. 我们围绕三类政策相关话题——生育意愿、个人养老金缴存与股票市场参与——实施在线访谈实验, 并比较了打字与语音两种输入方式的效果. 共收集到 525 份访谈样本, 平均访谈时长为 23 分钟. 结果表明, 相较于一次性的开放式问答, AI 访谈能够更系统地识别受访者在多轮对话中被激活的考虑因素 (主题), 并刻画其提及频率、出现轮次与主题共现模式, 从而揭示群体异质性, 且与封闭式问卷指标高度相关. 在主观评价方面, 超过 95% 的受访者对 AI 访谈给出正向总体评价, 多数受访者表示更倾向于 AI 主持访谈. 整体访谈与主题编码流程可复制、可审计并具备良好的可扩展性. 最后, 本文讨论了该方法在实际应用中的挑战及其潜在应对策略.

关键词 AI 访谈; 实验; 大语言模型; 生育意愿; 个人养老金缴存; 股票市场参与

AI Qualitative Interviews and Automated Thematic Coding: A Case Study for Three Policy-Related Topics

DONG Lu[1], HUANG Lingbo[2], LU Linlin[1]

(1. College of Business, Southern University of Science and Technology, Shenzhen 518055, China; 2. Center for Economic Research, Shandong University, Jinan 250100, China)

收稿日期: 2025-11-05
基金项目: 国家自然科学基金 (72573076, 72422018, 72394394, 72203099)
Supported by National Natural Science Foundation of China (72573076, 72394394, 72422018, 72203099)
作者简介: 董璐, 长聘副教授, 博士, 研究方向: 行为与实验经济学, 人工智能应用, 团队合作与竞争, E-mail: donglu@sustech.edu.cn; 通信作者: 黄凌波, 博士, 教授, 研究方向: 行为与实验经济学, 大国博弈, 市场设计, E-mail: lingbo.huang@sdu.edu.cn; 鲁琳琳, 博士研究生, 研究方向: 行为与实验经济学, 人工智能应用, E-mail: lull2025@mail.sustech.edu.cn.

Abstract With the rapid advancement of large language models (LLMs), the large-scale application of qualitative interviews in economics has become feasible. This paper introduces a multi-agent LLM–based approach to semi-structured qualitative interviewing and develops a complete workflow built upon it. In this framework, AI agents serve as interviewers to conduct standardized yet probing semi-structured interviews. Subsequently, LLMs, assisted by human reviewers, extract thematic insights and perform automated coding from the interview transcripts, thus achieving an integrated process from interviewing to coding. We implemented online interviews on three policy-relevant topics—fertility intentions, personal pension contributions, and stock market participation–and compared the performance of text-based and voice-based input modes. A total of 525 interviews were collected, with an average duration of 23 minutes each. The results indicate that, compared with one-off open-ended questioning, AI-led interviews can systematically elicit and track the considerations (themes) activated during multi-turn conversations-including their frequency, turn-level emergence, and co-occurrence patterns-reveal group heterogeneity, and produce results highly correlated with conventional closed-form survey measures. Subjectively, over 95% of participants reported positive overall evaluations of the AI interviews, and the majority of participants expressed a preference for AI-conducted interviews. The entire interview and coding pipeline is replicable, auditable, and highly scalable. Finally, we discuss the practical challenges of applying this method in real-world settings and potential strategies to address them.

Keywords AI interview; experiment; large language model; fertility intention; private pension contribution; stock market participation

1 引言

在经济学研究中, 显示性偏好一直被视为理解个体经济行为的黄金法则. 主流经济学长期以来主要依靠行政数据或实验室实验, 通过观察人们的实际选择来推断其潜在偏好, 从而检验理论假设或评估政策效果. 然而, 近年来学界逐渐认识到, 个体的主观信念与预期在经济决策中起着至关重要的作用 (Haaland et al., 2025). 无论是对宏观经济形势的判断、对收入分配的感知, 还是对政策效果的预期, 人们的主观想法往往深刻影响着其可观察的选择行为. 随着经济学研究对行为机制的关注不断深化, 理解并准确测量个体的主观信念, 已成为分析经济行为的重要前沿方向. 在这一背景下, 如何科学地引导和测量人们的主观想法, 成为新的研究重点. 过去, 这类研究往往受限于研究者的设计与主观解释, 而如今, 随着机器学习和大语言模型 (large language model, LLM) 等人工智能技术的迅速发展, 基于文本与开放式问答的质性数据正在成为经济学研究的重要补充. 通过精心设计的开放式问题, 研究者能够捕捉公众对核心经济议题的认知框架、观念体系与被激活的考虑因素, 从而为解释经济行为背后的动机、约束与叙事线索提供新的分析视角 (Stantcheva, 2023; Andre et al., 2026).

质性访谈 (qualitative interview), 作为一种开放式问答的研究方法, 尽管在社会学、人类学中已行之久远, 其在经济学中的采用仍受限, 根本约束在于较高的固定与边际成本、规模化困难以及对访谈主持人主观性的敏感 (Small and Calarco, 2022). 若通过算法辅助建立

一套可复制的标准化提取与编码机制, 质性访谈相较一次性开放式问答的增量价值在于: 利用迭代互动实时澄清与深挖, 进而更系统地揭示主观信念、偏好与思维模式, 并提升对潜在机制线索与主题结构的识别力. 大型语言模型的出现, 为上述标准化与规模化路径提供了现实可行的技术条件.

本文在 Chopra and Haaland (2023) 的基础上, 介绍了一种基于多个大型语言模型代理协同的 AI 质性访谈系统. 该系统在标准化流程下运行可调整的系统提示词, 显著降低实施成本, 并满足经济学研究对规模化与可复制性的要求, 从而拓展质性方法在经济学领域的应用边界. 相较于 Chopra and Haaland (2023) 的研究, 本文的创新主要体现在三个方面: 一是聚焦中文语境, 评估并验证了一套具有可扩展性与迁移潜力的访谈方案, 并将其应用于生育意愿、个人养老金缴存与股票市场参与这三类与公共政策高度相关的话题; 二是通过组间对照, 比较不同输入方式 (打字与语音) 对访谈数据质量与受访体验的影响, 从而比较交互形式对质性数据的作用机制; 三是实践了一套 “LLM 辅助 + 人工复核” 的多步骤主题分类与编码流程, 构建了访谈文本量化处理的系统化方法与质量评估框架.

高质量的 AI 访谈需同时满足四项要求 (Small and Calarco, 2022): 1) 内容深度: 问题与追问能够持续挖掘机制线索与关键考虑因素; 2) 非引导性: 措辞中性, 避免提前框架与价值判断; 3) 对话连贯性: 上下文记忆与滚动摘要维持主题线索与一致性; 4) 流程效率: 在有限时长内提升有效信息密度、降低受访疲劳. 为实现上述目标, 我们采用多代理 LLM 协同: 功能分工既保持对话开放自然, 又维持必要的标准化与可比性. 系统包含四类 LLM 代理: 切题代理提出核心问题并组织议题转换; 追问代理负责澄清与追问; 总结代理生成滚动式摘要以支撑后续提问与一致性控制; 安全代理监控潜在偏离与不当内容. 该多代理协调机制降低了单一访谈风格可能导致的异质性, 使研究者在控制成本的同时获取兼具深度与广度的访谈内容. 为提升受访体验并提升完成率, 我们在界面层模拟即时通信环境 (对话历史可视化、打字/语音输入反馈、拟真 “输入中” 提示), 以营造沉浸式交流氛围.

本文将生育意愿、个人养老金缴存与股票市场参与这三类政策相关话题作为 AI 访谈方法的试验场景: 它们同属经济学家与政策制定者高度关注、但仍存在显著争议与不确定性的领域. 三者共同面临识别上的挑战——传统问卷与行政数据难以充分捕捉个体的主观约束与心理机制; 同时, 若外部政策设定不当, 纠偏代价高昂. 围绕这三类决策, 既有研究已勾勒出若干稳健机制: 在生育意愿方面, 生育补贴与产假改革在因果识别框架下被发现能提升生育率, 而住房与教育成本上升、母职惩罚与文化规范则抑制生育 (Baker et al., 2008; Lalive and Zweimüller, 2009; Alesina et al., 2013; Dettling and Kearney, 2014; Raute, 2019; Kleven et al., 2019; Kim et al., 2024). 在个人养老金缴存方面, 参与率与缴费强度对制度与行为细节高度敏感: 自动加入与默认选项可显著提升参保与留存, 同伴效应、信息摩擦与金融素养亦发挥关键作用 (Madrian and Shea, 2001; Duflo and Saez, 2002; Thaler and Benartzi, 2004; Chetty et al., 2014). 在股票市场参与方面, 标准模型虽预测应普遍配置风险资产以获取股票溢价, 但现实中大量家庭并未入市, 股市参与难题三十年来尚无统一解释, 相关综述强调资金、信息、认知与制度等障碍的多维性 (Guiso and Sodini, 2013; Gomes et al., 2021; Duraj et al., 2025).

相较于传统问卷, 半结构化 AI 访谈为上述话题提供了一套可复制的研究路径: 在统一

提示与标准化流程下, 通过多轮追问与动态澄清, 将 “为何不生/少生” “为何不缴/少缴” “为何不入市/如何入市” 的具体卡点外显化, 并映射为可编码的主题与机制; 依托规模化, 低边际成本的实施, 具有覆盖难触达人群, 降低非响应并提升回答深度的潜力; 再以 LLM 辅助人工复核的多步骤主题/机制编码, 形成可复制流程. 由此获得的微观证据, 能为鼓励生育, 个人养老金和股市参与的相关政策提供更细致, 可操作的参考, 也能为传统的实证研究提供相互印证, 提高外部有效性的补充路径.

基于上述框架与话题设定, 在 2025 年 9 月, 我们依托 Credamo 见数平台开展了一项在线组间对照实验. 研究采用 3×2 的组间对照设计: 围绕上述三类话题实施半结构化 AI 访谈, 并在打字与语音两种输入方式之间进行对照. 共获得 525 份有效样本. 问卷流程分为三步: 1) 前置背景问题; 2) AI 访谈; 3) 对访谈的评价与补充封闭式问题. 基于该设计, 我们首先评估 AI 访谈的可行性与可接受度. 结果表明, 受访者在较长对话中能保持稳定投入: 访谈平均时长约 23 分钟, 85.8% 的受访者完成了全部问题[1]; 以答题耗时与字数衡量的参与度未随时间下降, 未出现显著问卷疲劳. 主观评价方面, 99.2% 的受访者给出正向总体评价; 绝大多数受访者对由 AI 主持访谈持开放态度, 表示更倾向于 AI 主持访谈[2].

在确认可行性之后, 我们转向评估该方法的增量价值. 我们关心两个问题: 第一, 与一次性开放式提问相比, 半结构化 AI 访谈是否能更完整地捕捉受访者的考虑因素, 并记录这些因素的提及顺序和共现关系? 第二, 访谈提取的信息能否与封闭式问题的测量相互印证? 结果显示, AI 访谈确实比单次开放式问答挖掘出更多的考虑因素, 且能追踪各因素在多轮对话中出现的先后和频次; 访谈中识别的因素与封闭式问题的回答存在显著相关. 总体来说, AI 访谈在保持标准化和可规模化的前提下, 同时产出了定性描述和可量化的编码数据, 为中文语境下的个体决策研究提供了一个可复制的工具. 下文先回顾开放式回答在经济学中的应用, 以便为本文方法提供参照.

2 开放式回答和大语言模型在经济学研究中的价值

经济学研究长期主要依赖结构化问卷和封闭式问题收集研究数据. 这类方法便于标准化, 进行量化构建模型和因果识别, 受访者只能在预设选项中作答, 回答受研究者的提问框架所限. 开放式问题则不同, 受访者可以用自己的话表达想法, 研究者由此可以观察到哪些因素是受访者主动提及的, 而不是被选项暗示的. Ferrario and Stantcheva (2022) 指出, 开放式回答的价值正在于避免框架效应, 获取未经引导的证据. 开放式问题在经济学中的应用近年来明显增多. 在公共政策认知方面, Stantcheva (2021, 2022) 利用开放式回答揭示了不同群体在税收与社会政策理解中的差异, 发现叙事框架和因果归因方式对政策态度有显著影响. 在宏观经济学领域, Andre et al. (2022, 2026) 及 Link et al. (2023) 收集开放式文本, 分析公众如何形成通胀预期和宏观经济判断, 为宏观建模提供了新证据和新视野. 在社会偏好研究中,

[1]退出率为 14.2%. 退出更常见于女性及 31∼50 岁人群, 在大规模推广 AI 访谈时, 可能需要针对这些群体进行设计优化 (如缩短访谈长度、增加进度提示、提供更清晰的退出/跳过机制、差异化激励). 但未发现退出显著由特定话题或话题交互驱动 (log-rank $p > 0.05$).

[2]本文所使用的数据、 代码和附录请参见科学数据银行 (ScienceDB) 期刊社区, DOI: 10.57760/sciencedb.31146 和 CSTR:31253.11.sciencedb.31146. 若使用文中数据信息, 请注明引文和数据出处.

Cappelen et al. (2025) 则用开放式回答研究个体对分配公平的看法, 拓展了对社会偏好形成机制的理解. 总体来看, 这些研究工作的共同点是: 开放式数据不只记录受访者的结论, 还保留了个体的认知和推理过程.

质性访谈与开放式问题有相通之处, 社会学和人类学长期使用质性访谈来了解个体如何感知和理解社会世界. 质性访谈的灵活性使研究者能在自然对话中追踪那些问卷及其他方法难以触及的主题, 进而深入挖掘个人的认知逻辑和考虑因素 (Rubin and Rubin, 2011; Knott et al., 2022). 根据研究需要, 访谈可采取结构化、半结构化或非结构化形式, 大型项目通常采用结构化或半结构化设计以保证可比性, 小规模研究则常采用约束较少的方式收集更加自然的受访者观点. 相比于单次开放式问答, 访谈的一大优势在于多轮再追问: 研究者可以在对话中澄清含义, 探讨受访者初始回答背后的原因. Tversky and Kahneman (1974) 关于可得性启发式的研究为此提供了认知层面的解释: 人在判断时倾向于调用最容易想起的信息, 而追问可以改变被调用的线索集合, 使最初未被提及的因素进入讨论. 也就是说, 多轮对话不只是在澄清, 还可能激活受访者原本没有表达的深层次考虑. 不过, 质性访谈的成本高, 难以大规模实施, 且访谈者自身的状态会影响结果 (Patton, 2002; Denzin et al., 2017). 例如, 已有研究表明, 访谈者的情绪状态会显著影响受访者的回答结果 (Himelein, 2016; Stefkovics and Sik, 2022).

大语言模型的出现使开放式问题和访谈方法的规模化成为可能. 大语言模型可以大幅降低文本编码的人工成本, 并在主题识别和文本量化上保持较高的一致性 (Ash and Hansen, 2023; Korinek, 2023). 学界也在更多场景中使用 LLM, 包括模拟受访者、辅助实验设计等 (Dominguez-Olmedo et al., 2024; Horton, 2023; Chang et al., 2024; 洪永淼和汪寿阳, 2024; Tranchero et al., 2024). Chopra and Haaland (2023) 将这一思路推进到访谈领域: 他们设计了基于多代理 LLM 的半结构化访谈, 在股票市场参与话题上完成了数百份访谈. 方法的成本远低于人工访谈, 并且发现受访者普遍持有一种 “主动投资心智模型” (把投资等同于选股和频繁关注行情), 这一发现与后续的封闭式测量相互印证. Haaland et al. (2025) 在关于开放式回答数据的综述中, 将基于 LLM 的访谈视为该领域的新方向, 认为它与实验和问卷的结合, 有助于识别主观因素对经济决策的因果影响.

除经济学文献中关于开放式问题与主观信念测量的研究外, 本文的方法设计亦可置于更广泛的人机交互心理学的研究之中. 该领域的经典研究表明, 当个体相信自己是在与计算机或自动化系统而非真实他人互动时, 其自我披露行为会发生系统性变化. Nass and Moon (2000) 的研究表明当个体明确知道交互对象是机器时, 仍会无意识地将人际互动中的社会规范 (如互惠与礼貌) 应用于人机交互之中. 与此同时, 研究发现, 非面对面交流以及视觉匿名性的增强, 会降低自我公众形象管理的压力, 从而促进更真实的态度表达 (Walther, 1996; Joinson, 2001). Lucas et al. (2014) 的随机实验显示, 仅仅是 “相信” 自己正在与自动化系统而非人类互动, 就足以显著降低评判恐惧与社会称许性偏差, 并提高对敏感或污名化信息的披露程度. 这些研究共同表明, AI 访谈可能通过降低受访者对负面社会评价的预期, 在涉及价值判断或社会规范压力的问题上, 为获取更真实的回答创造有利条件.

与此并行, 随着生成式 AI 与 LLM 的普及, 社会科学访谈中 “硅样本 (silicon samples)” 的做法逐渐兴起: 即利用 LLM 生成虚拟受访者以模拟不同社会群体的意见表达, 从而在不

直接依赖真实被访者的情况下进行问卷的预测性测试或预实验, 以提升外部效度与问卷设计的鲁棒性 (Argyle et al., 2023; Horton, 2023). 这一路径通常按人口特征 (如年龄、教育、收入或政治倾向) 生成回答, 用于提前评估题项的敏感性和潜在偏差. 实验表明, GPT-3.5-turbo 能较准确地复现总体均值水平的态度分布, 但倾向于低估方差、夸大极端立场, 对老年人或低教育群体之类的特定群体的拟合尤其不理想 (Santurkar et al., 2023; Bisbee et al., 2024). 生成式 AI 也被用来复现经典实验: Aher et al. (2023) 用 GPT-3 复刻了多项社会心理学实验, Hewitt et al. (2024) 则发现 GPT-4 虚拟被试在 476 个社会科学实验中的平均处理效应与真实结果的相关系数达到 0.85. Jiang et al. (2025) 基于世界价值观调查 (WVS) 和美国全国选举调查 (ANES), 用 GPT-4o 构建硅样本, 提出 Matching-LLM 方法将模型生成的回答与历史数据匹配, 在社会价值观与选举结果的预测上取得了明显改善. 对经济学而言, AI 生成的开放式回答既可用于信念测量, 也可充当低成本的虚拟测试平台, 辅助机制验证与问卷预测. 但其代表性和偏差仍需逐项评估.

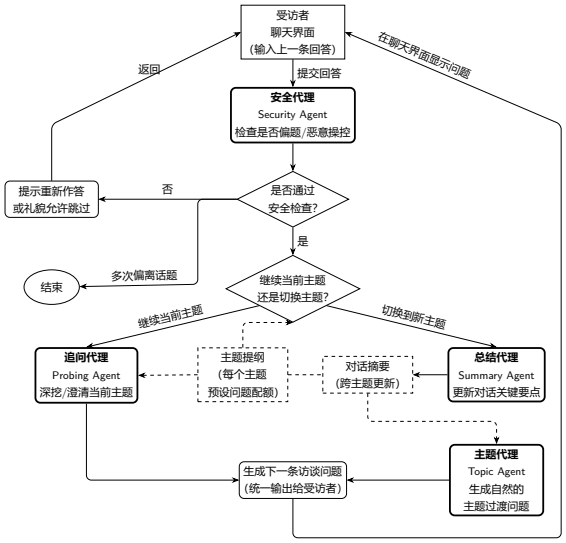
国内学界近年来也有不少相关工作. 在金融文本方面, 姜富伟等 (2024) 用适配中文金融语境的大语言模型构建市场情绪指标, 发现该指标在极端风险事件和市场下行阶段预测力更强; 陈友余等 (2024) 从上市公司管理层讨论与分析 (MD&A) 文本出发, 用机器学习构建企业风险识别模型, 为开放式文本在企业风险与财务预测研究中的应用提供了新的范式. 在测度方法上, 刘青和肖柏高 (2023) 用 BERT 模型对专利文本进行语义识别, 首次构建了劳动节约型技术创新指标, 发现劳动力成本上升促进了此类技术的自主创新; 金星晔等 (2024) 进一步用 ERNIE 模型从年报中提取企业数字化转型指标, 发现数字化转型通过效率提升和成本降低改善了企业财务绩效. 郝俞植和谢丹阳 (2025) 提出了基于多个 LLM 代理的经济与公共政策分析框架 (MLAB), 将不同模型的认知特征映射到社会经济群体, 以此模拟政策在不同阶层中的异质性影响, 为基于代理人的宏观经济建模和政策评估提供了新的方法论路径. 林建浩和孙乐轩 (2025) 综述了 GPT、BERT 及若干金融领域专用模型在经济与金融文本分析中的原理与应用, 指出当前亟需高质量中文经济金融语料和本地化模型. 在理论探索层面, 胡诗云和易君健 (2025) 则讨论了大语言模型如何改变经济管理学的研究方式, 认为 LLM 可在研究流程中承担参谋、助研和智能体等角色, 通过人机协作拓展研究的覆盖面.

尽管应用前景值得期待, AI 引入的方法论与伦理问题同样需要正视. 第一, LLM 容易继承训练数据中的性别、种族与阶层偏见, 可能在信念测量中造成系统性误差 (Bender et al., 2021; Santurkar et al., 2023); 徐磊等 (2024) 就此提出了数据平衡、对抗训练与后处理等缓解方案. 第二, 模型输出的概率性与时间漂移 (model drift) 会削弱结果的可重复性, 研究设计和报告阶段应明确模型版本、提示词与参数设置, 并辅以外部基准复核 (Chen et al., 2024; Ziems et al., 2024). 第三, AI 参与访谈或交互式实验可能引发隐私保护与研究伦理风险 (Weidinger et al., 2022). 据此, 有必要推进开源代码与透明训练数据的科研基础设施建设, 以降低对闭源商业模型的依赖 (Spirling, 2023). 同时, Bail (2024) 指出, 过度依赖封闭式商业模型不仅削弱研究的可重复性和透明度, 还可能在资源获取与研究能力之间重塑新的学术不平等. 为此, 他倡导社会科学界建立开放源代码与共享数据的研究基础设施, 以确保模型的可解释性、学术研究的可及性及伦理治理的可持续性.

3 AI 访谈的设计框架

本节介绍 AI 半结构化访谈的设计框架. 该框架由 Chopra and Haaland (2023) 提出并在英语语境中验证, 其核心思路是将一次访谈拆解为若干个可以复用的模块, 并由多代理协作完成: 安全代理、追问代理、切题/主题代理、总结代理. 系统全程以 “主题指南-对话历史-滚动摘要” 为主线: 研究者预设 3∼5 个核心议题, 并为每个议题设置问题预算, 表 1 以生育意愿访谈为例展示议题预设内容; 系统在 “继续追问” 与 “切换议题” 之间作出二元决策, 从而在保证覆盖面的同时获得足够的追问深度.

在具体实现上, AI 访谈系统采用多代理架构, 将访谈任务分解为多个专门化子任务. 当受访者通过聊天界面提交一条回复后, 系统首先启动安全代理 (security agent) 审核该回复是否符合访谈语境, 通过比对当前问题与回答的语义相关性来识别明显偏离主题或试图操控 AI 行为的内容. 若检测到不当内容, 系统会温和提示受访者重新作答; 若多次偏离话题, 则 AI 会自动结束访谈. 通过安全审核后, 系统根据主题提纲 (topic guide) 中当前议题的问题配额进行决策. 若配额未耗尽, 则由追问代理 (probing agent) 基于 “主题指南 + 最近对话历史 + 滚动摘要” 生成下一个追问问题. 若当前议题的配额已耗尽, 则由切题/主题代理 (topic agent) 生成自然过渡的引导语, 将对话衔接至下一个议题; 此时总结代理 (summary agent) 会读取刚结束议题的完整对话记录, 提取关键主题和受访者观点, 以去重方式将新信息整合进滚动摘要中. 当所有议题均被覆盖后, 系统提出两个预设的结束性问题, 随后由 AI 表达感谢并引导受访者进入后续调查问卷环节. 整个流程的可视化示意见图 1.



注: 该图完整展示了 AI 访谈的工作流程. 实线表示控制流, 虚线表示信息流. 主题提纲与对话摘要作为上下文信息, 同时流向追问代理 (用于在当前主题内深挖) 和主题代理 (用于生成主题过渡问题), 以确保生成的问题既符合访谈结构, 又能结合已有对话内容.

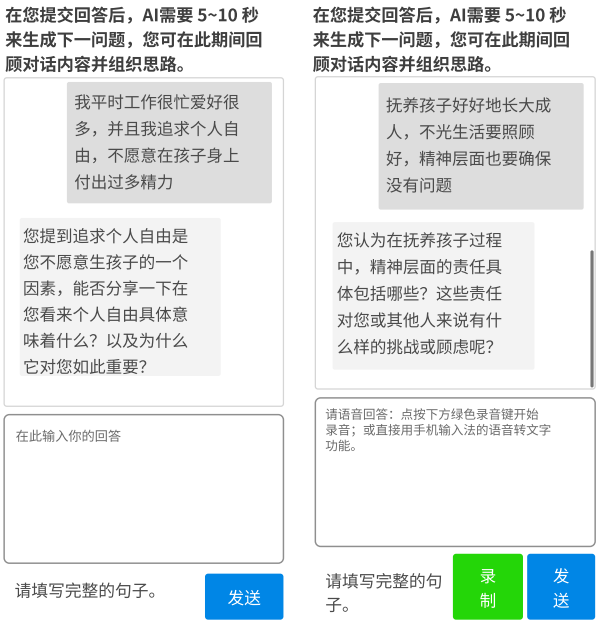
图 1 AI 访谈流程图

为保证访谈质量, AI 访谈员在提示词设计中需遵循质性研究方法的基本规范. 这主要体现在四个方面: 其一, 方法论规范, 即提问应保持开放性与非引导性, 具备自适应追问能力,

并在问题之间实现自然衔接, 从而兼顾局部细节与整体脉络; 其二, 一致性与稳定性, 要求 AI 访谈员在跨访谈及长时交互中忠实执行研究者指令, 维持稳定的角色表现; 其三, 安全性, 指系统应具备抵御恶意干扰的能力, 防止访谈过程被受访者操控或偏离研究目标; 其四, 伦理规范, 意味着在涉及敏感议题时, AI 访谈员需具备识别受访者情绪反应的能力, 尊重其中止或跳答的意愿, 并将相关信息纳入摘要以提醒后续提问避免二次刺激. 上述规范共同构成了 AI 访谈设计的行为边界与质量保障机制[3].

需要强调的是, 访谈中 AI 的角色定位与语言风格并非由模型自由生成, 而是通过系统级提示词进行统一约束 (附录 A 给出了各个代理的提示词). 所有代理均被明确要求使用中性、非引导性的提问方式, 避免价值判断、规范性评价或替受访者下结论, 从而降低不同访谈之间的风格异质性. 本研究未为访谈代理配置任何外部检索或知识增强 (RAG) 模块. 系统中唯一可调用的信息来源包括研究者事先设定的主题指南、访谈过程中生成的对话历史以及滚动摘要, 旨在避免将研究者立场、政策叙事或外部专家观点引入访谈过程, 从而影响受访者的自主表达与主题涌现.

在界面设计上, AI 访谈模拟即时通信聊天环境以提升受访者体验. 界面上方显示完整对话历史, 下方提供可编辑输入框与语音 “录制” 按钮. 受访者提交回答后, 系统在短暂延迟 (约 5 秒) 后生成下一问, 并通过 “三个点” 等待动画模拟自然对话节奏, 从而降低中途退出并提升沉浸感. 如图 2 所示, 图中展示了手机端的文字输入与语音输入界面.



注: 左侧为文字输入的访谈界面, 右侧为语音输入的访谈界面.

图 2　AI 访谈问答界面 (手机端示例)

[3]值得注意的是, 在其他应用场景或技术条件允许直接采集语音或多模态数据的情况下, 研究者有必要对匿名化处理与伦理审查提出更高要求, 并在设计阶段充分评估相应的数据保护机制, 以确保受访者隐私得到切实保障.

4 AI 访谈的三个应用

本文选取三个与公共政策密切相关的话题来展示 AI 访谈的应用潜力: 一是部分群体生育意愿偏低的原因; 二是部分群体未缴存个人养老金的原因; 三是部分群体未参与股票市场投资的原因. 现有文献围绕这三个话题已有大量实证研究, 但多以个体的实际决策数据为基础, 较少触及影响决策的主观信念、偏好和思维模式. 质性访谈数据恰好可以补充这一缺口, 帮助研究者了解决策背后那些在问卷中不易观测到的想法.

4.1 实验流程和访谈样本

本文设计了一个 3 × 2 的组间对照实验. 其中, 一个实验维度为三类访谈话题, 另一个实验维度为两种输入方式 (打字输入与语音输入)[4] 实验于 2025 年 9 月在 Credamo 见数平台实施, 共收集有效样本 525 份, 各实验组样本量在 81 至 92 之间. 所有实验组的问卷结构保持一致: 首先, 参与者回答 4、5 个与访谈话题相关的传统问卷问题. 以生育意愿话题为例, 问卷包含 “您未来三年是否计划生育 (包括再生育)?” 等问题. 随后, 参与者被告知将参与一次由 AI 聊天机器人主持的访谈, 并通过示例熟悉访谈界面及交互方式. 在阅读访谈须知并确认同意后, 参与者进入正式访谈环节. 最后, 访谈结束后, 参与者需完成关于 AI 访谈体验的评价问卷, 并回答若干与访谈话题相关的补充问题 (以封闭式问题为主). 本研究的样本完成时间的中位数为 35 分钟, 所有完成问卷并通过质量审核的参与者均获得 30 元固定报酬[5].

正式访谈采用半结构化形式, 流程固定, 围绕四个议题依次展开: 1) 开场开放式问题; 2) 阻碍与挑战的追问; 3) 条件情境设想 (请受访者假设若要考虑该行为, 需要具备哪些条件或做法); 4) 促成行为改变的条件. 全流程共 18 个问题, 具体轮次与安排见表 1. 以生育意愿访谈为例: 第一议题中, AI 的首问是 “您觉得人们不愿意生孩子的主要原因是什么? 如果方便, 也可以谈谈您个人的情况, 或者您认为他人不愿意生孩子的原因.” 这道题在形式上对应传统问卷中的一次性开放式问题, 便于与问卷基线做比较; 随后根据受访者的回答生成 5 轮动态追问, 补充关于 “原因” 的信息. 第二议题转向 “阻碍或挑战”, 再进行 5 轮追问, 激发受访者谈及前面没有提到的因素. 第三议题让受访者做假设性推演: 如果要考虑生育, 需要什么条件或做法, 通过 3 轮追问展开. 第四议题围绕 “目前不愿生育者需要哪些条件或改变才会考虑生育”, 进行 2 轮追问. 最后, 系统预设两个结尾问题, 收集补充信息并请受访者回顾; 访谈结束后, 系统生成对话总结, 并请参与者评价该总结是否准确.

[4]在语音输入组中, 受试者可选择通过录音方式表达想法, 系统会将录音自动转写为文字并填入回答框. 受试者在整个过程中仍可使用键盘输入或编辑转写文本. 由于实验未强制要求语音输入, 参与者需在访谈结束后的问卷中自报其主要输入方式, 以便研究者事后区分; 在语音组中, 78.4% 的受访者报告其主要采用语音输入. 需要说明的是, 尽管语音访谈在理论上有助于捕捉语调、停顿等副语言信息, 但受限于本文所使用的平台交互机制, 语音在进入访谈系统前即被转换为文本, 原始语音数据无法保存或访问, 因此本文未开展基于真实语音信号的多模态分析. 未来研究可在支持端到端语音交互的平台条件下, 进一步探讨语音信号在 AI 访谈中的信息价值.

[5]实验依托见数平台的在线问卷系统对接其样本库. AI 访谈环节以 HTML/JS 形式嵌入问卷, 但在研究团队自建服务器上运行并存储数据, 实现与平台的数据收集与存储隔离; 该安排既满足实验实施的技术需求, 也进一步提升了访谈数据的隐私与安全保护. 为合理补偿受访时间, 本研究向受访者支付的劳务报酬折算为平均每小时约 51 元, 显著高于平台常规时薪.

表 1　AI 半结构化访谈流程设计 (以生育意愿访谈为例)

阶段	提问内容示例	提问目标	轮次
开场预设	您觉得人们不愿意生孩子的主要原因是什么? 如果方便, 也可以谈谈您个人的情况, 或者您认为他人不愿意生孩子的原因.	提供与传统开放式问卷可比的问题, 建立访谈基线	1
动态追问	基于受访者的初始回答生成追问	深入探讨受访者本人或其认为他人不愿意生孩子的原因	5
阻碍因素	您提到的这些原因背后, 有哪些具体的阻碍或挑战?	引导受访者挖掘尚未涉及的因素	5
反事实设问	假如您或其他人考虑生孩子, 需要具备哪些条件或采取哪些做法?	借助反事实思维, 激发对潜在条件的思考	3
条件与改变	您认为目前不愿意生孩子的人需要哪些条件或改变才会考虑生孩子?	总结性探讨, 聚焦关键条件	2
结尾预设	在结束前, 您还有什么想补充的吗?	收集额外信息	1
结尾预设	回顾我们的对话, 您认为阻碍人们生孩子的主要原因是什么?	强化总结, 验证核心原因	1
总结反馈	系统生成对话总结, 请您评价该总结是否准确概括了访谈内容	验证 AI 总结质量	-

4.2 访谈质量与体验

为了获得更具人口代表性的样本, 除通过甄别题目排除在校学生外, 本研究未对样本特征设置其他额外限制[6]. 在确保数据质量方面, 我们采取了四项措施. 第一, 问卷开端设有注意力检验题, 未通过者直接剔除. 第二, 由于含 AI 访谈的问卷耗时明显长于见数平台的常规问卷, 我们在入口处告知参与者这是一项 “20 分钟 AI 访谈”, 报酬固定为 30 元; 正式访谈前, 参与者需阅读须知, 其中说明只有完成全部访谈与后续问卷且通过质量审核后方可获得报酬. 第三, 为减少因隐私顾虑而中途退出的情况, 须知承诺所有数据严格匿名且仅用于学术研究[7]; 同时, 为缓解实验者需求效应 (experimenter demand effect) 和社会称许性偏误 (social desirability bias, Bursztyn et al. (2025)), 须知中强调回答无对错, 参与者只需根据真实想法作答. 第四, 为减少受访者直接用设备自带的大语言模型生成回答, 访谈界面禁止了复制粘贴功能 (PC 端和移动端均适用). 另外, 本研究的提问均与日常生活相关, 多数受访者平时已有所思考, 并非冷僻或高度专业的问题, 作答负担不大, 借助外部 LLM 生成回答的动机

[6]样本共 525 人, 其中女性占 55.8%; 年龄分布: 21∼30 岁 (48.2%)、31∼40 岁 (40.6%)、41∼50 岁 (6.1%)、51∼60 岁 (5.1%). 多数受访者学历为本科 (72.0%), 另有 16.9% 为研究生及以上. 家庭年收入集中在 10∼40 万元之间 (82.5%). 职业方面, 61.1% 受访者来自民营企业, 30.3% 来自国有单位, 另有少量来自外资企业 (6.1%) 及其他职业 (2.5%).

[7]在数据收集与存储方面, 本研究采取了多项措施以保护受访者隐私. 首先, 受限于平台技术条件, 本研究并未收集或保存任何原始语音数据: 语音输入仅用于即时转写, 在进入访谈系统前即被转换为文本, 研究者无法访问或存储原始音频文件, 后续分析亦完全基于匿名化的文本数据进行, 因此不存在基于语音信号识别个体身份的可能性. 其次, 本研究的 AI 访谈系统运行于研究团队自建服务器之上, 其数据存储与问卷平台相互独立、物理隔离, 从而进一步降低了潜在的隐私泄露风险.

也较弱.

为全面评估 AI 访谈的可行性与有效性, 我们从客观行为指标与主观体验两个方面展开分析. 从客观行为指标来看, AI 访谈整体表现出较高的可执行性与稳定性. 所有回收问卷中, 访谈记录完整的比例达到 85.8%, 表明样本流失率较低、参与质量较好[8]. 如图 3 所示, 访谈时长主要集中在 10∼30 分钟之间, 平均时长约为 23 分钟. 每个问题的平均回答时间约为 1.5 分钟, 在四个预设议题中并未出现显著的递减趋势, 说明受访者在整个过程中始终保持稳定投入. 就文本产出而言, 总字数主要分布在 0.5∼1.5 千字区间 (平均 1085 字), 单题平均回答字数保持在 60∼70 字, 显示出 AI 访谈能够在限定时间内获取较为充分的语料. 结合描述性统计结果表 2 可见, 语音输入组的回答字数整体高于文字输入组, 印证了自然口语表达更为流畅的直觉假设. 另外, 编码结果显示, AI 访谈员高度遵循其显性指令: 99% 的问题被编码为开放式提问, 97% 被编码为非引导性, 98% 被编码为高度相关[9].

表 2 每个实验组的基本描述性统计

	样本量	平均时长 (秒)	平均字数
生育意愿-打字	97	29.07	54.21
生育意愿-语音	81	22.10	68.30
个人养老金缴存-打字	91	23.76	57.63
个人养老金缴存-语音	83	22.40	59.84
股票市场参与-打字	92	23.25	48.92
股票市场参与-语音	81	26.42	69.26

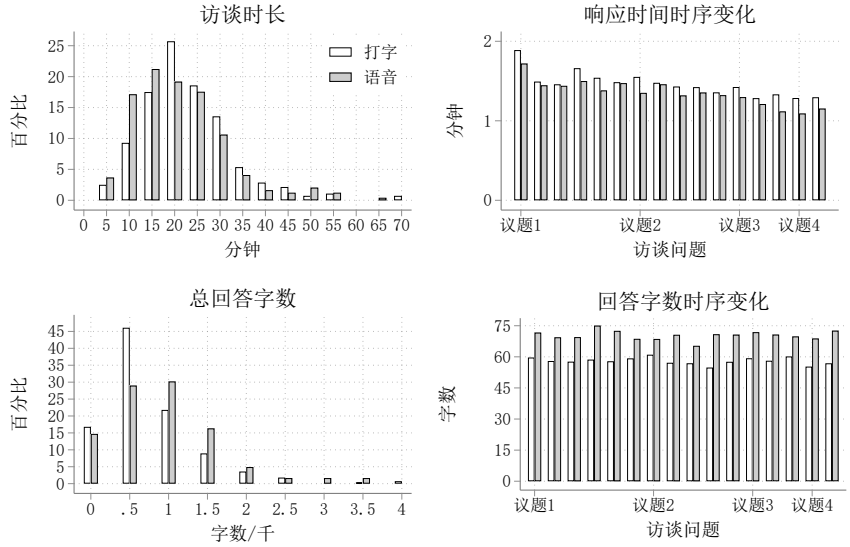
注: 平均时长是指每次从问题生成到受访者提交回答所花费的平均时长. 平均字数是指每次回答输入的平均字数.

在主观体验层面, 受访者普遍对 AI 访谈给予积极评价. 如图 4(a) 所示, 无论是整体体验还是对话自然程度, 选择比较好及以上评价的受访者均占绝大多数, 负向反馈比例极低. 就访谈员偏好而言, 超过半数受访者表示更倾向于由 AI 主持访谈, 或认为 AI 与真人主持之间差异不大. 这一结果与现有研究中关于 AI 访谈可接受性的发现一致 (参见 Chopra and Haaland, 2023), 表明 AI 访谈在受访者中已具备较好的社会认同度与信任基础. 进一步将主观体验细化至具体维度 (图 4(b)), 多数受访者认为 AI 的响应速度令人满意、提问清晰易懂, 并普遍认可 AI 的追问能够帮助深入思考. 同时, 大部分受访者表示在 AI 访谈中能够较为自在地表达真实想法. 整体来看, 这些结果与图 3 所揭示的客观访谈指标相互印证, 说明 AI 主

[8]退出分析显示: 女性退出率 (14.1%) 显著高于男性 (7.2%, $\chi^2(1) = 6.88$, $p < 0.01$), 31∼40 岁与 41∼50 岁人群退出率 (15.8%、20.0%) 显著高于 21∼30 岁人群 (5.6%, $\chi^2(3) = 17.07$, $p < 0.01$). 但退出率在收入 ($p = 0.50$)、学历 ($p = 0.73$) 与话题类型 ($p = 0.22$) 上均无显著差异. Kaplan-Meier 生存分析显示三个话题的累计退出曲线高度重合 (log-rank 检验, $p > 0.05$), 包含话题 × 性别、话题 × 收入、话题 × 学历的交互 logit 模型显示交互项联合检验不显著, 表明退出并未集中在特定话题 × 特定群体的组合上.

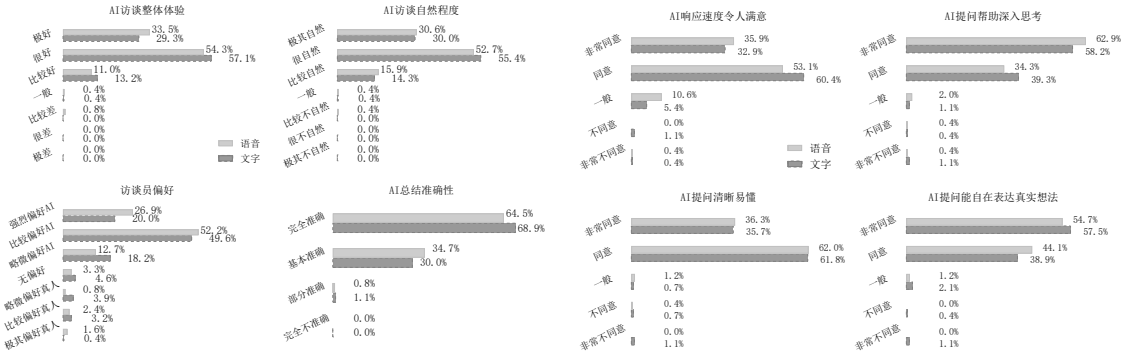
[9]为检验 AI 访谈是否在实际运行中遵循开放性、非引导性与相关性等方法论指令, 我们对全部 AI 生成的追问文本进行了事后人工编码. 两名研究助理在不知晓具体访谈话题与输入方式的情况下, 依据预先制定的编码标准, 分别判断每一条问题是否属于开放式提问、是否存在预设立场或暗示性表述, 以及是否紧扣当前访谈主题与受访者前序回答.

持的半结构化访谈在本研究情境下, 既能维持受访者的参与度, 又能为后续的主题分析与编码工作提供质量可靠的文本基础.



注: 议题 1: 开场开放式问题; 议题 2: 阻碍/挑战的深入探讨; 议题 3: 设想条件情境的提问 (请受访者 “假设” 若要考虑该行为, 需要具备哪些条件或采取哪些做法); 议题 4: 促成行为改变的关键条件.

图 3　访谈参与度分析



(a) 整体评价　　(b) 具体维度评价

图 4　访谈评价

4.3 访谈文本的主题分类以及编码的步骤

本研究的文本分析采用 “LLM 辅助-人工复核” 的多步骤主题分类与编码流程. 研究首先利用 LLM 进行初步的主题识别与归纳. 具体而言, LLM 对每位受访者的完整访谈记录进行总结, 并提炼出 5∼20 个尽量不重复的关键要点. 随后, 研究团队成员随机抽取约 30 条摘要进行阅读, 以初步了解主要谈话主题的分布, 并验证模型提炼结果合理性. 在此基础上, 我们重新启动全新会话的 LLM, 对所有访谈摘要再次进行归纳, 提炼出 20∼40 个更高层级的

主题. 为确保结果的稳健性, 该过程重复进行三次, 并在不同会话下生成三组独立的主题集合. 三位合作者分别独立审阅模型输出结果, 并经充分讨论后修订主题边界与命名, 使各主题既保持内部一致, 又具备外部区分性. 经多轮比对与讨论后, 团队确立初步主题分类体系.

随后, 我们再次启动新的 LLM 会话, 将上述初步主题分类结果与第一步生成的访谈摘要相结合, 为每个主题撰写详细的操作性定义, 并从完整的访谈记录中提取具有代表性的语句作为示例. 这一阶段相当于构建初版编码本. 在此基础上, 我们选取五份访谈记录作为样本, 依据该初版编码本对每组问答逐条进行编码. 研究团队根据试编码结果, 对存在定义重叠、边界模糊或表述不清的条目进行修订, 经过多轮迭代修改, 最终形成正式版本的完整编码本 (见附录 B).

在正式编码阶段, 我们按照上述最终编码本, 用 LLM 对所有访谈逐条问答做主题判定, 判断每条回答是否属于一个或多个主题[10]. 这里的目的不是给每条文本贴上尽可能完整的标签, 而是观察各主题在多轮叙事中何时出现、如何演变[11]. 为降低任务复杂度, 各主题的判定独立进行. 我们先在随机抽取的小样本上测试, 评估模型编码的一致性和准确性, 并在不改变主题框架的前提下微调提示词. 为提高结果的稳健性, 本研究同时调用三家公司的 LLM —— OpenAI GPT-4o-mini、Google Gemini-2.5-flash 和 xAI Grok-4-fast —— 并行执行相同任务, 以多数投票原则确定最终归类[12]. 各模型的 temperature 参数均设为 0, 以最小化输出的随机性.

在完成全部编码后, 我们计算了三种模型输出结果之间的一致性. 总体而言, 三者编码完全一致的比例为 92.1%, Fleiss' Kappa 系数为 0.64, 属于一致性较高的水平 (Landis and Koch, 1977). 该结果与现有文献中人工编码者之间的相关性水平基本相当 (Chopra and Haaland, 2023)[13]. 进一步分析显示, LLM 之间的两两一致性也较为接近: GPT-4o-mini 与 Gemini-2.5-flash、GPT-4o-mini 与 Grok-4-fast、以及 Gemini-2.5-flash 与 Grok-4-fast 之间的编码一致比例分别为 95.6%、94.2% 和 94.4%, 对应的 Fleiss' Kappa 系数分别为 0.66、0.64 和 0.62. 若按访谈话题分别考察, 无论是在生育意愿、个人养老金缴存还是股市参与三个话题下, 模型间编码完全一致的比例均超过 91%, Kappa 系数均处于 0.62∼0.67 范围内[14].

需要指出的是, 由于本研究旨在比较同一访谈话题中不同输入方式 (打字与语音) 所带

[10]Chopra and Haaland (2023) 采用了传统的人工编码方案.

[11]我们关注访谈文本中哪些主题 (考虑因素) 被提及, 在访谈的第几轮被提及, 以及主题之间的共现模式. 按照认知科学与经济学文献中更严格的界定, 心智模型或叙事强调个体如何在叙事中组织因果关系、内在联系与解释结构; 只有在对因果方向与解释链条进行刻画时, 才能将开放式回答严格界定为叙事或心智模型 (Shiller, 2017; Andre et al., 2026). 本文当前的实证分析并未直接对这一层面的因果组织方式进行建模.

[12]在实际执行过程中, 考虑到访谈话题的样本量与主题数量, API 共计调用约 49.2 万次, 花费约 431 元.

[13]Fleiss' Kappa 在计算中控制了随机一致性的影响, 相较于简单的百分比一致率, 更能准确反映编码结果的一致性. 然而, 该指标可能受到类别分布不均或项目难度差异的影响, 因此本文同时报告百分比一致率以供参考.

[14]多项研究显示 LLM 在政治言论、社交媒体文本和开放式问答数据的主题识别、立场分类与框架分析方面已接近甚至超过人工编码员 (Gilardi et al., 2023; Wu et al., 2023; Ziems et al., 2024). 特别是在多语言语料与大规模数据情境下, AI 的优势体现在编码一致性与处理效率上. Törnberg (2023) 则提供了利用 API 与提示词工程开展社会科学文本分析的实践指南, 强调 "人机协同" 在确保分析质量与解释一致性方面的重要性.

来的差异, 因此主题分类必须基于合并后的整体样本统一进行, 以确保 “判罚尺度” 的一致性. 若在分组样本的前提下分别进行主题归类, 观察到的差异可能难以区分是由输入方式本身导致, 还是仅仅源于大语言模型输出的随机性.

4.4 访谈话题一: 生育意愿

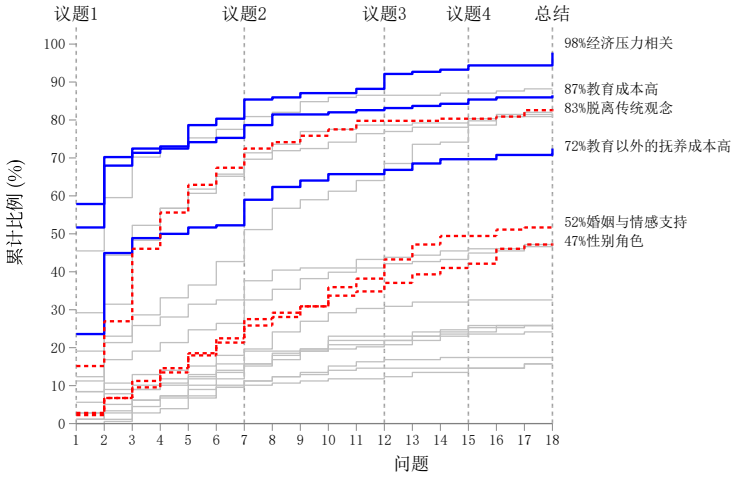
基于表 3 的编码结果, 本节从主题的出现频率与出现阶段两个维度出发, 分析生育意愿的主要内容结构与形成机制. 分析区分了两类主题: 一类主题在首次回答中就高频出现, 是受访者对生育约束的直觉反应; 另一类在首次回答中较少出现, 但在完整访谈中明显增多, 是经追问后才被谈及的因素. 两类主题的差异说明, 半结构化 AI 访谈的多轮追问确实能够挖掘出受访者最初未提及的考虑. 图 5 展示了各主题在访谈过程中的累积出现比例, 反映了主

表 3　生育意愿的主题类型和分布

	(1) 打字输入	(2) 语音输入	(3) 全部访谈	(4) 首次回答
经济与物质压力类				
经济压力相关	97.9%	97.5%	97.8%	57.9%
教育成本高	85.6%	87.7%	86.5%	51.7%
教育以外的抚养成本高	66.0%	80.2%	72.5%	23.6%
多孩压力	13.4%	18.5%	15.7%	2.8%
养育回报不确定	19.6%	14.8%	17.4%	1.1%
未来不确定性	48.5%	46.9%	47.8%	11.2%
职场与社会结构压力类				
社会资源与公平不足	79.4%	85.2%	82.0%	8.4%
社会焦虑氛围	30.9%	21.0%	26.4%	1.1%
生育政策认知	12.4%	19.8%	15.7%	0.0%
职场压力	84.5%	77.8%	81.5%	29.2%
社会竞争压力	48.5%	45.7%	47.2%	12.4%
家庭与人际关系类				
性别角色	50.5%	43.2%	47.2%	2.8%
原生家庭与代际观念差异	23.7%	28.4%	25.8%	1.1%
婚姻与情感支持	49.5%	54.3%	51.7%	2.2%
父母支持有限	21.6%	30.9%	25.8%	2.8%
心理与生活方式类				
时间成本精力与责任	91.8%	84.0%	88.2%	45.5%
个人自由受限	81.4%	81.5%	81.5%	19.1%
脱离传统观念	82.5%	82.7%	82.6%	15.2%
生养孩子的心理恐惧	33.0%	32.1%	32.6%	8.4%
身体与健康风险类				
健康风险	22.7%	25.9%	24.2%	5.6%

注: 本表的编码以每一条 “问题-答案” 为独立分析单元. 每条回答可能涉及多个不同的主题, 因此各主题的出现比例之和超过总回答数. (1) 与 (2) 列分别对应打字与语音输入组的全部访谈, (3) 列展示全部访谈, (4) 列展示首次回答, 可类比于传统问卷中的单次开放性问答.

题涌现的动态轨迹. 由于打字与语音输入两组在主题分布上无显著差异, 以下分析基于合并样本.



注: 该图展示了每个主题在访谈过程中被提及的累积人数比例, 并突出了基线机制和某些后发主题. 议题 1: 开场开放式问题 (您觉得人们不愿意生孩子的主要原因是什么? 如果方便, 也可以谈谈您个人的情况, 或者您认为他人不愿意生孩子的原因); 议题 2: 阻碍/挑战的深入探讨; 议题 3: 设想条件情境的提问 (请受访者“假设”若要考虑生育孩子, 需要具备哪些条件或采取哪些做法); 议题 4: 促成行为改变的关键条件.

图 5 生育意愿主题的累积发现过程

整体来看, 受访者在生育意愿的表达中首先聚焦于可量化、可感知的现实约束, 形成了以经济负担、生活节奏与职场压力为核心的基线机制. 经济与物质压力几乎贯穿所有访谈, 是受访者最直接、最普遍的顾虑. 教育、住房、托育和日常抚养支出被反复提及, 其中经济压力 (97.8%)、教育成本 (86.5%) 和教育以外的抚养成本 (72.5%) 出现频率最高. 心理与生活方式方面的顾虑也十分普遍, 约 88.2% 的受访者提到时间精力与责任相关内容, 认为生育会压缩个人时间、加重身心负担. 典型表述包括“工作强度高、难以兼顾育儿”和“缺少自主支配的生活空间”. 职场与社会结构的压力同样突出, 约 81.5% 的访谈提及这一话题, 许多受访者担心生育会带来岗位替代、晋升受阻或绩效下降等风险.

与上述在首次回答中就高频出现的主题不同, 部分主题在首次回答中出现频率较低, 但在随后的追问中明显上升. 这一变化反映出半结构化访谈在促进受访者反思与延展思维时的激活效应, 使一些潜在但重要的议题得以浮现. 如图 5 所示, 这些后发主题主要集中在社会支持、性别分工与价值观层面. 其中, 社会资源与公平不足的变化最为突出, 从首次回答的 8.4% 上升至完整访谈的 82.0%. 当受访者被问及“如果要考虑生育, 你需要具备哪些条件”时, 教育资源不均、学区门槛和托育服务可得性等问题被集中提出. 许多人提到“为了上优质小学要买学区房、还要报辅导班, 托育名额也难抢、费用高”, 反映出社会结构性约束对生育决策的重要影响[15].

[15]这些主题与一项最新的实证研究结果相契合. 该研究发现, 2021 年民办教育禁令的实施显著提升了居民的生育意愿, 其主要作用机制在于降低了公众对教育竞争压力的预期 (Meng et al., 2025).

婚姻与情感支持在追问中的增幅也很大, 从 2.2% 上升到 51.7%. 受访者在进一步思考后更明确地谈到伴侣分工、父母帮衬与家庭弹性对生育决定的影响. 如一位受访者所言: “如果伴侣不分担、父母也无法帮衬, 一个人带娃会累垮, 因此不敢轻易生”. 性别角色的讨论也在深入交流中明显增多, 从 2.8% 升至 47.2%. 许多受访者在后续谈话中反思 “生育代价由谁承担”, 提到女性生育惩罚、男性育儿分工不足, 以及隐性绩效评价等问题, 揭示了社会性别分工的惯性与职场文化的结构性偏差.

个人自由受限与脱离传统观念这两个主题也有明显的后发特征. 前者从 19.1% 上升至 81.5%, 后者从 15.2% 升至 82.6%. 受访者把机会成本具体化为 “旅行、自我成长、弹性生活节奏” 的丧失, 典型表述如 “担心以后不能随时旅行、进修或自由安排时间”, 显示出人们对自主性与生活掌控的考虑与重视. 随着访谈深入, 不少受访者进一步表达了对婚育自主选择、反对传宗接代、性别角色重估等观念的认同, 如 “不想结婚、不想为了孩子降低生活质量, 对传宗接代不再认同”. 这些回答反映了代际之间价值观念的明显转变与家庭意义的重新定义. 从整体趋势看, 后发主题的出现说明: 当访谈从表层经济成本转向情感、角色与价值层面时, 受访者的考量也从 “能否负担” 过渡到 “是否愿意”.

在性别差异方面, 男女样本的主题分布在若干议题上存在显著不同. 女性受访者更频繁地提及性别角色 (55% vs. 37%, $p = 0.018$)、原生家庭与代际观念差异 (33% vs. 17%, $p = 0.014$) 以及健康风险 (29% vs. 18%, $p = 0.087$); 男性则更多谈到未来不确定性 (58% vs. 40%, $p = 0.019$). 简言之, 女性讨论生育意愿时更多从家庭结构与性别分工出发, 男性则更关注宏观经济和社会环境的不确定性. 这种差异体现出生育决策背后性别化经验的结构性分布: 女性倾向于从社会角色和资源分配角度作出决策, 男性则更侧重外部条件与环境可控性的评估.

需要指出的是, 后发主题的出现并非一蹴而就, 而是在访谈过程中通过持续追问与互动逐步被激活的结果 (见图 5). 不同主题的后发程度存在显著差异, 这表明访谈过程并非对所有潜在议题的简单覆盖, 而是一个具有选择性与层次性的探索过程. 换言之, 受访者并不会机械地重复既有观点, 而是在动态交流中逐步形成更完整的表达. 为了进一步验证这些后发主题的真实性, 我们将访谈识别的主题与问卷中后续封闭式多选题 —— “您本人未计划/不愿意生孩子, 或您认为别人不愿意生孩子的主要原因有哪些?” —— 进行了对应分析. 结果显示, 每一个可与问卷选项对应的后发主题均呈现相关性. 需要强调的是, 这些问卷选项在访谈前已预设, 并与访谈部分在同一问卷中完成, 从而排除了研究者 “事后归因” 的可能. 例如, 编码为 “社会资源与公平不足” 的主题与选择 “缺乏可靠的托育/幼儿园/保姆等服务资源” 之间的卡方检验统计量为 10.734 ($p = 0.001$). 这一结果进一步验证了后发主题并非受访者的临时性回应, 而是其真实想法的系统性体现.

由上面的发现可以看出, 生育意愿的考虑因素并非一次性浮现. 经济与时间精力是受访者最先提到的约束, 而结构性资源、性别与职场文化、生活方式与价值观等因素则在追问中才逐渐被谈及. 仅靠一次性开放题, 这些后发主题容易被遗漏; 半结构化追问和反事实设问有助于把它们呈现出来. 政策上可从三方面入手: 一是提升可负担且高质量的托育与教育资源供给, 缓解 “学区-托育-课外” 压力; 二是改善职场的生育友好度, 强化反歧视、晋升保障与陪产假制度; 三是通过公共传播与社会示范, 削弱 “生育必然牺牲自我” 的刻板印象, 在尊重个

体选择的前提下拓宽政策空间.

4.5 访谈话题二：个人养老金缴存

与前述生育意愿话题类似, 个人养老金缴存的访谈结果同样呈现出由显性约束向隐性机制逐步展开的结构 (见表 4). 整体来看, 受访者的主要顾虑集中于三类基线机制: 经济与收入约束、认知与信息获取障碍, 以及政策与制度信任问题. 经济压力 (94.8%)、短期消费与长期承诺冲突 (82.8%) 与长期收益不确定性 (70.7%) 构成了 “当前资金用途-未来收益可信度” 的核心张力. 认知与宣传障碍 (89.7%)、金融知识缺乏 (83.3%) 和养老意识不足 (78.7%) 表明, 信息触达与理解不足仍是从 “知情” 到 “行动” 的主要阻力. 政策复杂性 (48.9%) 与信任障碍 (73.6%) 进一步说明, 制度的清晰度与可预期性与收益水平同样重要.

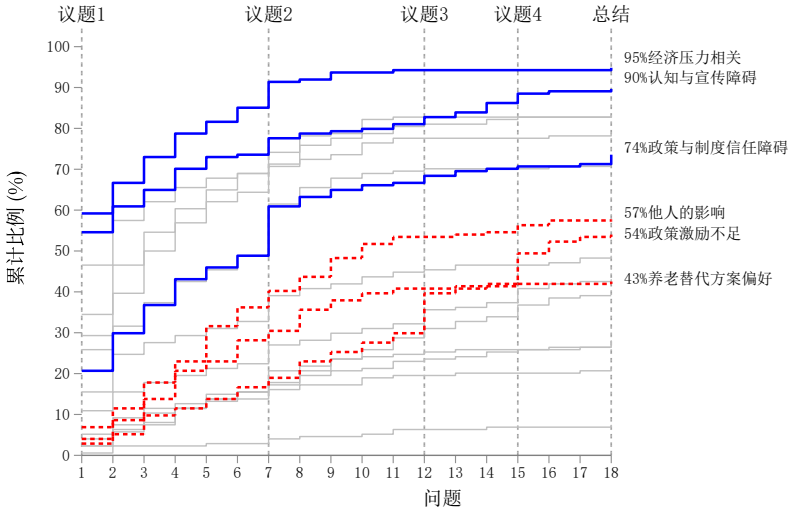
表 4 个人养老金缴存的主题类型和分布

	(1) 打字输入	(2) 语音输入	(3) 全部访谈	(4) 首次回答
经济与收入约束类				
经济压力相关	96.7%	92.8%	94.8%	59.2%
收入不稳定	33.0%	22.9%	28.2%	2.3%
短期消费与长期承诺冲突	80.2%	85.5%	82.8%	29.3%
长期收益的不确定性	72.5%	68.7%	70.7%	25.9%
政策与制度信任类				
政策复杂性	51.6%	45.8%	48.9%	15.5%
政策与制度信任障碍	72.5%	74.7%	73.6%	20.7%
对制度公平性的担忧	23.1%	30.1%	26.4%	4.0%
信息安全问题	5.5%	9.6%	7.5%	0.6%
政策激励不足	57.1%	50.6%	54.0%	2.9%
不想被强制	37.4%	41.0%	39.1%	2.3%
认知与信息获取障碍类				
认知与宣传障碍	91.2%	88.0%	89.7%	54.6%
技术与流程障碍	38.5%	48.2%	43.1%	10.9%
金融知识缺乏与财务规划不足	85.7%	80.7%	83.3%	46.6%
养老意识不足与用途模糊	78.0%	79.5%	78.7%	34.5%
心理预期与偏好类				
悲观的寿命预期	24.2%	18.1%	21.3%	5.2%
养老替代方案偏好	40.7%	44.6%	42.5%	4.0%
社会与人际影响类				
他人的影响	57.1%	57.8%	57.5%	6.9%

注: 本表以每一条 “问题-答案” 为独立分析单元. 每条回答可能涉及多个不同的主题, 因此各主题的出现比例之和超过总回答数. (1) 与 (2) 列分别对应打字与语音输入组的全部访谈, (3) 列为全部访谈, (4) 列为首次回答, 可类比于传统问卷中的单次开放式问答.

在追问环节中, 受访者的回答逐步扩展至更隐性的心理与行为因素. 图 6 展示了主题的累计发现过程. 一方面, “政策激励不足” 从 2.9% 升至 54.0%, 多数受访者认为 “税优额度小、收益一般, 不足以弥补锁定成本”; “不想被强制” 从 2.3% 升至 39.1%, 反映出对 “自愿原则”

的强调与对行政化约束的抵触; “养老替代方案偏好” 从 4.0% 升至 42.5%, 不少人表示更倾向于通过房产、存款或商业保险实现养老积累, 认为 “更直观也更灵活”. 另一方面, “他人影响” 与 “技术障碍” 的上升 (分别从 6.9% 到 57.5%, 10.9% 到 43.1%) 显示, 社会口碑与数字体验对参保行为具有显著的放大效应. 典型表述包括: “亲友说手续麻烦、收益不高, 大家都没办, 我也就算了”; 或 “APP 认证、绑卡屡次失败, 太繁琐就放弃了”.



注: 该图展示了每个主题在访谈过程中被提及的累计人数比例, 并突出了基线机制和某些后发主题. 议题 1: 开场开放式问题 (您觉得人们不去开立或缴纳个人养老金的主要原因是什么? 如果方便, 也可以说说您个人的情况, 或者您看到别人不参与的原因.); 议题 2: 阻碍/挑战的深入探讨; 议题 3: 设想条件情境的提问 (请受访者 “假设” 若要考虑参缴个人养老金, 需要具备哪些条件或采取哪些做法); 议题 4: 促成行为改变的关键条件.

图 6　个人养老金缴存主题的累计发现过程

异质性分析显示, 不同群体在后发主题上的表达存在显著差异. 已开立并缴存者更常提及 “养老替代方案偏好” (54% vs. 23%, $p < 0.001$), 显示实际参与者更倾向于多元化资产配置; 年轻群体 (21∼30 岁) 同样更重视灵活性与可控性 (53% vs. 34%, $p = 0.010$). 将这些后发主题与问卷中 “您或他人不参缴个人养老金的主要原因有哪些?” 的结果对照发现, 各主题均与相应选项显著相关, 例如, “政策激励不足” 与 “税收优惠对我帮助不大” 之间的卡方统计量为 6.081 ($p = 0.014$). 这表明访谈中激发出的隐性机制与受访者的真实考量一致.

总体而言, 个人养老金缴存的阻碍体现为 “现金流与流动性偏好-收益与政策预期-制度信任与可用性” 的多重作用. 半结构化访谈揭示的 “激励不足” “替代方案偏好” 等后发主题, 补充了常规调查难以捕捉的行为与心理机制. 针对这些障碍, 政策上可从三方面改进: 第一, 优化税优政策与产品设计, 推出低费率、目标日期类产品, 缓解资金锁定与收益不确定的矛盾; 第二, 简化流程、稳定规则、强化资金安全与公平保障, 增强制度信任; 第三, 改善信息触达与数字体验, 提供一站式服务与温和 “轻推” (默认选但可随时退出), 以在自愿基础上提升参与率.

4.6 访谈话题三：股票市场参与

股市参与率的访谈结果同样呈现出由显性约束向隐性机制递进的特征 (见表 5). 整体来看, 受访者在首次回答阶段主要聚焦于风险与能力两方面的基线约束. 首先, 几乎所有受访者都提及 “风险与损失厌恶”, 整体出现率高达 99.4%, 首次回答即达 85.5%. 多数人表示 “怕被套” “担心本金亏损”, 说明风险感知的显性化是进入股市的首要心理门槛. 与此紧密相关的 “市场波动性与不可预测性” (75.7%) 进一步强化了 “风险感知-行为回避” 的连锁反应. 其次, 投资知识与规划不足构成另一重要障碍, 整体出现率为 94.2%, 首次回答 52.6%. 许多受访者坦言 “不会选股” “缺少学习渠道”, 而 “信息不对称与难以获取可靠信息” (64.2%) 则揭示出知识缺口与信息壁垒共同造成了 “不会-不敢” 的参与困境.

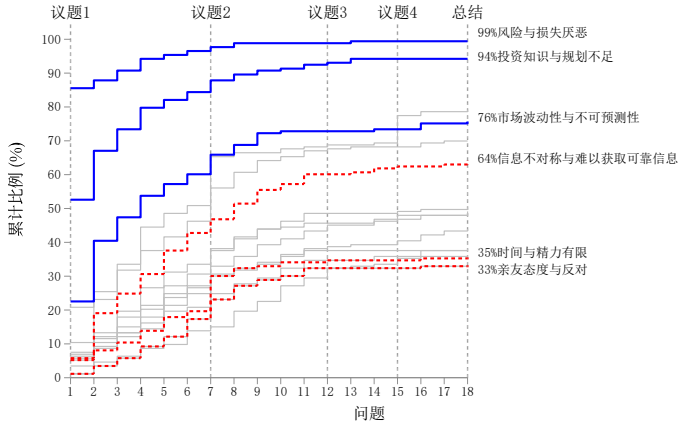
表 5　股票市场参与的主题类型和分布

	(1) 打字输入	(2) 语音输入	(3) 全部访谈	(4) 首次回答
经济与收入约束类				
收入与流动资金不足	77.2%	81.5%	79.2%	20.8%
时间与精力有限	35.9%	34.6%	35.3%	5.2%
认知与能力不足类				
投资知识与规划不足	94.6%	93.8%	94.2%	52.6%
信息不对称与难以获取可靠信息	59.8%	69.1%	64.2%	5.8%
依赖专业人士或机构	37.0%	38.3%	37.6%	1.2%
风险感知与心理因素类				
风险与损失厌恶	98.9%	100.0%	99.4%	85.5%
市场波动性与不可预测性	75.0%	76.5%	75.7%	22.5%
收益预期与现实落差	29.3%	43.2%	35.8%	6.4%
心理承受能力不足	43.5%	55.6%	49.1%	7.5%
失败经历与负面案例影响	66.3%	74.1%	69.9%	10.4%
社会与人际影响类				
亲友态度与反对	31.5%	34.6%	32.9%	1.2%
舆论与社会氛围影响	52.2%	44.4%	48.6%	3.5%
外部环境与制度信任类				
经济环境不佳	45.7%	55.6%	50.3%	5.2%
制度不确定性与市场不信任	40.2%	48.1%	43.9%	5.8%
投资偏好类				
替代选择丰富	32.6%	44.4%	38.2%	6.9%

注: 本表的编码以每一条 “问题-答案” 为独立分析单元. 每条回答可能涉及多个且不同的主题, 因此各主题的出现比例之和超过总回答数. (1) 列打字输入组的全部访谈数据, (2) 列语音输入组的全部访谈数据, (3) 列全部访谈数据, (4) 列每个访谈记录的第一个回答, 可以和传统问卷中的一次性开放性问答做类比.

在追问环节中, 部分隐性机制被逐步激活, 受访者开始从个人经验、社会氛围与制度环境角度反思参与障碍. 图 7 展示了主题的累计发现过程. 首先, “失败经历与负面案例影响” 的出现率从 10.4% 升至 69.9%, 许多人提到 “被套” “踩雷” 等亲身或间接经历, 认为 “亏过一次就难再信任股市”. 这类经历常与 “心理承受能力不足” 并行, 后者从 7.5% 升至 49.1%,

部分人表示股价波动会引发焦虑, 甚至影响房贷和日常资金安排. “舆论与社会氛围影响” 从 3.5% 升至 48.6%, 受访者提到媒体与社交平台上的 “亏损叙事” 会影响自己的判断, 如 “行情差时满屏都是股灾段子, 更不敢入场”. 制度不确定性与市场不信任也在追问中频繁出现 (从 5.8% 升至 43.9%), 受访者担忧 “庄家操纵” “政策多变” 及 “退市风险”, 认为 “钱放进去心里没底”, 显示出制度环境的不透明感对投资信心的抑制.



注: 该图展示了每个主题在访谈过程中被提及的累计人数比例, 并突出了基线机制和某些后发主题. 议题 1: 开场开放式问题 (您觉得人们不去买股票或基金的主要原因是什么? 如果方便, 也可以说说您个人的情况, 或者您觉得别人不投的原因); 议题 2: 阻碍/挑战的深入探讨; 议题 3: 设想条件情境的提问 (请受访者 “假设” 若要考虑参与股票市场, 需要具备哪些条件或采取哪些做法); 议题 4: 促成行为改变的关键条件.

图 7　股票市场参与主题的累计发现过程

经济环境与时间精力方面的顾虑在深入交流中同样增多. 经济下行、熊市效应和市场流动性不足被认为削弱了短期收益预期, 使谨慎态度加剧 (从 5.2% 升至 50.3%). 另外, 部分受访者表示 “上班没时间盯盘” “学习曲线太陡”, 时间与精力的约束 (从 5.2% 升至 35.3%) 是持续参与的现实障碍. 这些后发主题说明, 股市参与率偏低不只是因为风险认知本身, 还涉及信息不对称、制度信任不足和情绪传播等因素.

异质性方面, 股票或基金持有者与非持有者之间在若干主题上差异显著. 例如失败经历与负面案例影响 (54% vs. 73%, $p = 0.039$) 和市场波动与不可预测性 (61% vs. 79%, $p = 0.043$) 均呈显著差异; 此外, 频率查看股市人群 (至少每日一次) 也更倾向表达对市场波动的关注 (81% vs. 68%, $p = 0.046$), 但较少提到经济环境不佳 (44% vs. 60%, $p = 0.034$). 进一步地, 我们将访谈中识别的后发主题与问卷后续的封闭式多选题 —— “您或他人不参与股票市场投资的主要原因有哪些?” —— 的回答进行了对照分析. 结果显示, 每一个可与问卷选项明确对应的后发主题均与该选项呈现显著相关性. 例如, 编码为 “时间与精力有限” 的主题与选择 “管理投资组合成本太过 (时间、精力、资金)” 之间的卡方检验统计量为 12.900 ($p < 0.001$).

进一步地, 在上述被追问激活的深层因素中, 与 Chopra and Haaland (2023) 所述 “active investing mental model” (主动选股心智模型) 最为接近的是 “时间与精力有限”, 并与 “投资知识与规划不足” “信息不对称与难以获取可靠信息” “心理承受能力不足” 共同构成 “认知-

时间-情绪” 的复合门槛. 横向对比中美样本, 均观察到后发主题在完整访谈中被系统性激活, 尤其是信息可得性、他人/舆论影响与过往失败经历在首次回答阶段被系统性低估; 不同之处在于, 我们样本中 “风险与损失厌恶” 在首答即处于高位 (85.5%), 风险感知更为显性. 同时, 相较于美国样本, 我们的样本中对 “制度不确定性与市场不信任” “经济环境不佳” 等宏观和制度因素在追问中的上浮趋势更加明显.

股市参与的障碍从表面看是风险感知与知识不足, 但追问后可以看到, 失败经历、舆论环境和制度不确定性在更深层面塑造了回避倾向. 针对这一发现, 政策上可以三个方面着力, 一是改善信息披露与投资者教育, 提升透明度与金融素养; 二是完善监管与退市机制, 增强制度公信力; 三是优化中小投资者的服务环境, 提供低风险理财与稳健投资渠道, 在风险可控的前提下引导理性参与.

4.7 跨话题比较与讨论

综合来看, 三个话题呈现出相似的结构: 首次回答中, 受访者倾向于报告更直接、可见的原因; 经过半结构化追问和反事实设问后, 回答扩展到更隐性的心理、制度与社会情境因素, 形成一组在首答中被低估、但在完整访谈中明显上升的后发主题. 这种从基线主题到后发主题的展开, 在生育意愿和个人养老金缴存中都很明显, 股票市场参与话题也是如此. 三个话题在基线层面有共同点: 首答阶段集中于约束性因素. 生育意愿中, 经济压力、教育成本与时间精力责任出现频率最高. 个人养老金缴存中, 经济压力、认知与宣传障碍、金融知识不足构成经济与认知的双重门槛. 股票市场参与中, 风险与损失厌恶、投资知识不足在首答阶段占主导.

尽管三话题均存在 “首答低、追问后显著上升” 的共同现象, 但后发主题的内容指向具有明显差异. 生育意愿的后发主题更多聚焦社会支持、性别分工与价值观层面: 例如 “社会资源与公平不足” (从首答 8.4% 上升至 82.0%), “婚姻与情感支持” “性别角色” “个人自由受限” 与 “脱离传统观念” 等有显著的后发主题特征, 显示个体在访谈中的考量从 “能否负担” 逐步过渡为 “是否愿意”. 个人养老金缴存的后发主题则集中在制度激励、自愿性与使用摩擦: 如 “政策激励不足” (2.9% 上升至 54.0%)、“不想被强制” “养老替代方案偏好” “他人的影响” 与 “技术与流程障碍” 均在追问中被显著激活. 股票市场参与的后发主题更突出经验与制度环境: 如 “失败经历与负面案例影响” “舆论与社会氛围影响” “制度不确定性与市场不信任” 与 “经济环境不佳” 在追问中上浮.

从访谈过程看, 由于访谈话题的预设, 三类话题的主题涌现均呈现阶段性: 议题 1 为开场开放式问题, 议题 2 对阻碍/挑战进行深入探讨, 议题 3 引入条件情境设问, 议题 4 聚焦促成改变的关键条件. 在这一结构下, 后发主题往往并非在议题 1 即充分出现, 而是在议题 2∼4 的追问与反事实框架中被逐步唤起并获得更具体的表达空间.

上述现象可以从可得性启发式的角度理解. 首答阶段, 受访者的判断受当下最容易想到的线索主导, 因此最先报告的往往是易于提取、社会上高度可见的理由, 如经济压力或风险担忧, 这些理由对应的是以直观成本收益为核心的启发式判断 (Tversky and Kahneman, 1974). 半结构化追问和反事实设问的作用, 不只是让受访者 “想得更深”, 而是改变了判断时可被调用的线索集合及其权重, 使原本不容易想到的因素 (如社会支持、制度信任、流程摩擦、舆

论叙事) 进入讨论, 并被组织为可陈述的解释. 由此看, 三个话题中的后发主题不是噪声或事后合理化, 而是线索权重切换后呈现的系统性差异. 生育话题更容易激活与身份和价值相关的因素, 如自主性、性别分工与公平感. 个人养老金话题突出的是制度激励与摩擦成本 (锁定期、默认缺失、流程阻力) 以及社会信息的放大效应. 股票市场话题则体现了负面经验与信息不对称在线索权重中的主导地位, 以及制度信任和情绪传播对风险感知的叠加影响. 因此, 后发主题反映的是在不同可得性与框架条件下, 启发式判断权重重新分配的结果.

为定位 AI 访谈在社会科学研究工具箱中的位置, 表 6 从信度、效度、实施成本、可扩展性与适用场景五个维度, 对 AI 访谈、传统人工访谈与封闭式问卷做了概念性比较.

表 6　AI 访谈、传统人工访谈与封闭式问卷的比较

维度	AI 访谈	传统人工访谈	封闭式问卷
信度	较高 (标准化执行、多模型表决)	中等 (依赖访谈员培训与一致性)	高 (题项固)
效度	中高 (多轮追问挖掘深层机制, 但受提示词影响)	高 (灵活追问、情感互动、非语言线索)	中 (受预设框架限制)
实施成本	低 (边际成本极低, API 调用费用低于 1 元/份)	高 (人力密集、培训成本高)	低 (规模化成本低)
可扩展性	高 (跨语言、跨地域潜力大)	低 (受访谈员数量与时间限制)	高
适用场景	规模化机制挖掘、政策前测、开放式探索	高敏感议题、深度个案、情感密集型研究	验证性研究、 大规模态度测量

在信度方面, AI 访谈通过标准化提示词和多模型表决, 能在大规模实施中保持较高一致性; 传统人工访谈的信度取决于访谈员的培训质量和个体差异控制; 封闭式问卷因题项固定, 信度最高. 在效度方面, AI 访谈可以通过多轮追问挖掘受访者的深层考虑, 但效度受提示词设计影响; 传统人工访谈在情感互动、非语言线索捕捉与灵活追问上有独到之处, 效度最高; 封闭式问卷则受限于研究者的预设框架, 难以捕捉框架之外的信息.

5　总结与讨论

本文旨在探索以较低成本、可复制并可规模实施的质性数据获取路径, 验证了一种基于大型语言模型的半结构化访谈以及质性数据分析框架, 并在生育意愿、个人养老金缴存与股票市场参与三大公共政策话题中开展了系统性实验. 基于上述实验结果, 本文的贡献可从方法论、理论与实践三个层面加以总结.

在方法论层面, 本文验证了一套 “多代理协同访谈-LLM 辅助多模型表决编码-人工复核” 的完整工作流程. 该流程的核心创新在于: 1) 多代理协同访谈框架将访谈任务分解为切题、追问、总结与安全审核四个模块, 在保持对话开放性与自然性的同时维持高度的标准化与可比性, 实验结果表明 99% 的问题为开放式提问、97% 为非引导性, 验证了该框架在方法论规范上的有效执行; 2) 多模型并行编码机制 (三家 LLM 独立编码后表决) 实现了 92.1% 的编码一致率与 0.64 的 Fleiss’ Kappa 系数, 有效降低了人工干预对质性分析一致性的影响, 为未来在更大样本、更广话题上的 AI 访谈应用提供了可扩展且可复现的技术路径; 3) 在中文语境下的系统验证与打字/语音输入方式的组间对照, 评估了该方法的跨语言迁移能力与交

互形式对数据质量的影响.

在理论层面, 三类话题的实验结果为半结构化追问的 “主题激活效应” 提供了系统性证据, 并与认知心理学中的可得性启发式理论形成对接. 如前文文献综述所述, Tversky and Kahneman (1974) 的可得性启发式理论预测, 个体在初始判断中倾向于调用最具显著性与易提取性的信息线索. 本文三类话题的实证结果系统性地支持了这一预测: 受访者在首答阶段均以显性的、可量化的约束性因素为主导 (如经济压力、风险厌恶), 而半结构化追问与反事实设问通过改变检索线索集合及其相对权重, 系统性地激活了一组在首答中被低估但在完整访谈中显著上升的 “后发主题” —— 生育话题中的社会支持与价值观、养老金话题中的制度激励与流程摩擦、股市话题中的负面经验与制度信任. 这些后发主题在三类话题中均呈现 “首答低、追问后显著上升” 的共同模式, 而其内容指向的系统性差异 (身份价值、制度摩擦、信息不对称) 进一步表明, 追问所激活的并非随机噪声, 而是受话题领域特征调节的认知权重重新分配. 这一发现将可得性启发式从个体判断层面拓展至访谈方法论层面, 为半结构化追问 “为何有效” 以及 “激活了什么” 提供了可检验的理论解释.

在实践层面, 上述主题激活效应的发现具有直接的政策含义. 通过揭示影响因素的层级结构与激活顺序, 该方法为政策制定者提供了更具解释力的微观依据: 首答中高频出现的基线因素 (如经济压力) 指示了公众最直接的政策诉求, 而追问后浮现的后发因素 (如制度信任、流程摩擦、社会公平感) 则揭示了传统问卷难以捕捉的深层政策着力点. 例如, 个人养老金话题中 “政策激励不足” 从首答 2.9% 升至 54.0% 的显著跃升, 提示政策设计不仅需关注经济补贴, 更需优化制度激励与操作便利性. 这种 “基线因素-后发因素” 的双层结构使干预设计能够从个体心理与社会语境出发, 优化政策优先级的排序与组合策略. 受访者对访谈体验的整体积极评价 (99.2% 正向评价, 多数倾向 AI 主持) 进一步验证了该方法在社会科学研究中的可行性与可接受度.

上述三个层面的贡献构成了一套完整的方法验证逻辑: 方法论层面的标准化框架与编码机制确保了数据收集与分析的可靠性; 理论层面的 “主题激活效应” 为追问环节的增量价值提供了认知心理学的解释基础; 实践层面的 “基线-后发” 双层主题结构则将方法论的有效性转化为可操作的政策启示. 三者共同表明, AI 半结构化访谈不仅在技术实现上可行, 而且在信息挖掘深度上具有超越一次性开放式问答的系统性优势. 需要指出的是, 本文采用的 LLM 辅助的主题分类方法并不以涌现新理论或因果关系为目标, 因此不适用于需要高度解释性理论建构的研究问题. 相较之下, 其优势在于能够在大规模文本材料中提供稳定、一致且可复现的主题识别结果. 未来研究可在本方法的基础上, 让 LLM 尝试提取具有因果方向与解释链条的叙事或心智模型, 结合人工深度分析或扎根理论取向, 开展更深入的概念发展与理论提炼.

尽管本研究未设置真人访谈对照组, 已有文献为 AI 访谈在敏感话题上的可能优势提供了理论支持. 社会称许性偏差 (social desirability bias) 是指受访者倾向于给出符合社会期望的回答, 而非真实想法 (Bursztyn et al., 2025). 研究表明, 当对话对象是计算机或虚拟代理时, 受访者的社会赞许性顾虑会降低. Lucas et al. (2014) 发现, 受访者面对虚拟人类访谈员时, 比面对真人时更愿意披露心理健康方面的敏感信息. Pickard et al. (2016) 也表明虚拟交互能降低评价焦虑, 促进敏感信息的自我披露. 本研究涉及的生育意愿、养老金缴存与股市

参与话题均有一定的个人敏感性社会规范压力, AI 访谈可能有助于受访者更坦诚地表达真实顾虑, 但这一点有待未来通过 AI 与真人访谈的直接对照实验来检验.

尽管本研究提出的 AI 访谈框架在可行性和创新性方面表现良好, 但其在方法论上仍存在若干需要审慎对待的局限, 有必要明确其适用边界. 首先, 与所有基于自我报告的数据收集方法类似, AI 访谈同样可能受到事后合理化和社会称许性偏差的影响, 使受访者倾向于给出更符合社会规范的回答; 如前所述, 相较于传统人工访谈, AI 访谈通过降低人际互动压力在一定程度上缓解了该问题, 但并不能完全消除. 其次, AI 访谈虽可减少人工访谈中的访谈员异质性, 其表现仍依赖于大语言模型的版本、提示词设计及参数设置, 不同模型或提示词方案可能在提问风格、追问深度与主题激活路径上存在差异. 为降低由此带来的不确定性, 本文固定模型版本与核心参数, 并在分析阶段引入多模型并行编码与表决机制, 以增强结果的稳健性与可复现性. 再次, 机器人样本与内容污染构成规模化实施中的潜在风险, 需要结合平台反机器人机制、语义检测与人工抽查加以控制. 最后, 尽管 AI 访谈在成本与规模化方面具有优势, 其在情感互动、伦理风险与隐私保护方面仍难以完全替代人工访谈, 涉及高度敏感议题时更适合采用人工访谈或人机协作的混合模式.

综上, 大语言模型驱动的 AI 质性访谈为经济学研究提供了一种低成本、可规模化的工具. 未来研究可从几个方面拓展. 在样本层面, AI 访谈可以突破语言与地域限制, 通过适配不同语言和文化的提示词, 覆盖传统调查难以触及的群体. 在数据整合方面, AI 访谈可以嵌入大规模纵向调查, 与行为数据、政策冲击或实验干预结合, 检验叙事与选择之间的因果关系. 在技术层面, 结合语音输入、情绪识别和语调分析的多模态访谈, 可以提升交互的自然度. 在科研规范方面, 推进提示词、编码本与分析脚本的开源, 有助于提高透明度与可重复性. AI 半结构化访谈使研究者不仅能记录人们说了什么, 还能了解他们为什么这样想, 为政策制定提供更细致的证据. 综合来看, AI 半结构化访谈不仅拓展了社会科学研究的边界, 也为政策制定提供了详细的证据基础. 它使研究者能够了解人们 “说了什么” 和 “为什么这样想”, 从而在机制层面连接个体认知、行为选择与政策反应的全过程.

参　考　文　献

陈友余, 赵金晶, 王欣, 刘纯霞, (2024). 基于文本分析和机器学习的企业风险识别研究 [J]. 计量经济学报, 4(6): 1671–1690.

Chen Y Y, Zhao J J, Wang X, Liu C X, (2024). Enterprise Risk Identification Based on Text Analysis and Machine Learning[J]. China Journal of Econometrics, 4(6): 1671–1690.

郝俞植, 谢丹阳, (2025). 基于多个 LLM 代理的经济和公共政策分析框架 [J]. 计量经济学报, 5(3): 615–630.

Hao Y Z, Xie D Y, (2025). A Multi-llm-agent-based Framework for Economic and Public Policy Analysis[J]. China Journal of Econometrics, 5(3): 615–630.

洪永淼, 汪寿阳, (2024). ChatGPT 与大模型将对经济学研究范式产生什么影响?[J]. 计量经济学报, 4(1): 1–25.

Hong Y M, Wang S Y, (2024). How Will ChatGPT and Large Models Influence the Research Paradigm in Economics?[J]. China Journal of Econometrics, 4(1): 1–25.

胡诗云, 易君健, (2025). 智能之光: 人机协作的经济管理研究新时代 [EB/OL]. [2025-10-25].

https://nsd.pku.edu.cn/xzyj/cbw/tlg1/tlg2025/542317.htm.

Hu S Y, Yi J J, (2025). The Light of Intelligence: A New Era of Economic Management Research in Human-Machine Collaboration[EB/OL]. [2025-10-25].
https://nsd.pku.edu.cn/xzyj/cbw/tlg1/tlg2025/542317.htm.

姜富伟, 刘雨旻, 孟令超, (2024). 大语言模型、文本情绪与金融市场 [J]. 管理世界, 40(8): 42–64.

Jiang F W, Liu Y M, Meng L C, (2024). Large Language Model and Textual Sentiment Analysis in Chinese Stock Markets[J]. Journal of Management World, 40(8): 42–64.

金星晔, 左从江, 方明月, 李涛, 聂辉华, (2024). 企业数字化转型的测度难题: 基于大语言模型的新方法与新发现 [J]. 经济研究, 59(3): 34–53.

Jin X Y, Zuo C J, Fang M Y, Li T, Nie H H, (2024). Measurement Problem of Enterprise Digital Transformation: New Methods and Findings Based on Large Language Models[J]. Economic Research Journal, 59(3): 34–53.

林建浩, 孙乐轩, (2025). 大语言模型与经济金融文本分析: 基本原理、应用场景与研究展望 [J]. 计量经济学报, 5(1): 1–34.

Lin J H, Sun L X, (2025). Text Analysis in Economics and Finance with Large Language Models: Fundamentals, Applications, and Future Prospects[J]. China Journal of Econometrics, 5(1): 1–34.

刘青, 肖柏高, (2023). 劳动力成本与劳动节约型技术创新——来自 AI 语言模型和专利文本的证据 [J]. 经济研究, 58(2): 74–90.

Liu Q, Xiao B G, (2023). Labor Costs and Labor-saving Innovation: Evidence from AI Language Model and Patent Texts[J]. Economic Research Journal, 58(2): 74–90.

徐磊, 胡亚豪, 潘志松, (2024). 针对大语言模型的偏见性研究综述 [J]. 计算机应用研究, 41(10): 2881–2892.

Xu L, Hu Y H, Pan Z S, (2024). Review of Biased Research on Large Language Model[J]. Application Research of Computers, 41(10): 2881–2892.

Aher G V, Arriaga R I, Kalai A T, (2023). Using Large Language Models to Simulate Multiple Humans and Replicate Human Subject Studies[C]// Proceedings of the 40th International Conference on Machine Learning: 337–371.

Alesina A, Giuliano P, Nunn N, (2013). On the Origins of Gender Roles: Women and the Plough[J]. The Quarterly Journal of Economics, 128(2): 469–530.

Andre P, Pizzinelli C, Roth C, Wohlfart J, (2022). Subjective Models of the Macroeconomy: Evidence From Experts and Representative Samples[J]. The Review of Economic Studies, 89(6): 2958–2991.

Andre P, Haaland I, Roth C, Wiederholt M, Wohlfart J, (2026). Narratives about the Macroeconomy[J]. The Review of Economic Studies, rdag014.

Argyle L P, Busby E C, Fulda N, Gubler J G, Rytting C, et al. (2023). Out of One, Many: Using Language Models to Simulate Human Samples[J]. Political Analysis, 31(3): 337–351.

Ash E, Hansen S, (2023). Text Algorithms in Economics[J]. Annual Review of Economics, 15: 659–688.

Bail C A, (2024). Can Generative AI Improve Social Science?[J]. Proceedings of the National Academy of Sciences, 121(21): e2314021121.

Baker M, Gruber J, Milligan K, (2008). Universal Child Care, Maternal Labor Supply, and Family Well-Being[J]. Journal of Political Economy, 116(4): 709–745.

Bender E M, Gebru T, McMillan-Major A, Shmitchell S, (2021). On the Dangers of Stochastic Parrots: Can Language Models be too Big?[C]// Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency: 610–623.

Bisbee J, Clinton J D, Dorff C, Kenkel B, Larson J M, (2024). Synthetic Replacements for Human Survey Data? The Perils of Large Language Models[J]. Political Analysis, 32(4): 401–416.

Bursztyn L, Haaland I, Röver N, Roth C, (2025). The Social Desirability Atlas[EB/OL]. [2025-10-25]. National Bureau of Economic Research. https://doi.org/10.3386/w33920.

Cappelen A W, Falch R, Tungodden B, (2025). Experimental Evidence on the Acceptance of Males Falling Behind[J]. Journal of the European Economic Association, 23(6): 2212–2240.

Chang Y, Wang X, Wang J, Wu Y, Yang L, et al. (2024). A Survey on Evaluation of Large Language Models[J]. ACM Transactions on Intelligent Systems and Technology, 15(3): 1–45.

Chen L, Zaharia M, Zou J, (2024). How is ChatGPT's Behavior Changing over Time?[EB/OL]. [2025-10-25]. Harvard Data Science Review, 6(2). https://doi.org/10.1162/99608f92.5317da47.

Chetty R, Friedman J N, Leth-Petersen S, Nielsen T, Olsen T, (2014). Active Vs. Passive Decisions and Crowd-Out in Retirement Savings Accounts: Evidence from Denmark[J]. The Quarterly Journal of Economics, 129(3): 1141–1219.

Chopra F, Haaland I, (2023). Conducting Qualitative Interviews with AI[R]. Social Science Research Network. https://papers.ssrn.com/abstract=4583756.

Denzin N K, Lincoln Y S, Maclure M, Otterstad A, Torrance H, et al. (2017). Critical Qualitative Methodologies: Reconceptualizations and Emergent Construction[J]. International Review of Qualitative Research, 10(4): 482–498.

Dettling L J, Kearney M S, (2014). House Prices and Birth Rates: The Impact of the Real Estate Market on the Decision to Have a Baby[J]. Journal of Public Economics, 110: 82–100.

Dominguez-Olmedo R, Hardt M, Mendler-Dünner C, (2024). Questioning the Survey Responses of Large Language Models[C]// Advances in Neural Information Processing Systems, 37: 45850–45878.

Duflo E, Saez E, (2002). Participation and Investment Decisions in a Retirement Plan: The Influence of Colleagues' Choices[J]. Journal of Public Economics, 85(1): 121–148.

Duraj K, Grunow D, Haliassos M, Laudenbach C, Siegel S, (2025). Rethinking the Stock Market Participation Puzzle: A Qualitative Approach[R]. CESifo Working Paper. https://hdl.handle.net/10419/324971.

Ferrario B, Stantcheva S, (2022). Eliciting People's First-order Concerns: Text Analysis of Open-Ended Survey Questions[J]. AEA Papers and Proceedings, 112: 163–169.

Gilardi F, Alizadeh M, Kubli M, (2023). ChatGPT Outperforms Crowd Workers for Text-annotation Tasks[J]. Proceedings of the National Academy of Sciences, 120(30): e2305016120.

Gomes F, Haliassos M, Ramadorai T, (2021). Household Finance[J]. Journal of Economic Literature, 59(3): 919–1000.

Guiso L, Sodini P, (2013). Household Finance: An Emerging Field[M]// Constantinides G M, Harris M, Stulz R M. Handbook of the Economics of Finance, Vol. 2. Amsterdam: Elsevier, 2013: 1397–1532.

Haaland I K, Roth C, Stantcheva S, Wohlfart J, (2025). Understanding Economic Behavior Using Open-ended Survey Data[J]. Journal of Economic Literature, 63(4): 1244–1280.

Hewitt L, Ashokkumar A, Ghezae I, Willer R, (2024). Predicting Results of Social Science Experiments Using Large Language Models[EB/OL]. Stanford: Stanford University. https://samim.io/dl/Predicting%20results%20of%20social%20science%20experiments%20using%20large%20language%20models.pdf.

Himelein K, (2016). Interviewer Effects in Subjective Survey Questions: Evidence From Timor-leste[J]. International Journal of Public Opinion Research, 28(4): 511–533.

Horton J J, (2023). Large Language Models as Simulated Economic Agents: What Can We Learn from Homo Silicus?[R]. National Bureau of Economic Research. https://www.nber.org/papers/w31122.

Jiang S, Wei L, Zhang C, (2025). Donald Trumps in the Virtual Polls: Simulating and Predicting Public Opinions in Surveys Using Large Language Models[R]. arXiv. http://arxiv.org/abs/2411.01582.

Joinson A N, (2001). Self-disclosure in Computer-mediated Communication: The Role of Self-awareness and Visual Anonymity[J]. European Journal of Social Psychology, 31(2): 177–192.

Kim S, Tertilt M, Yum M, (2024). Status Externalities in Education and Low Birth Rates in Korea[J]. American Economic Review, 114(6): 1576–1611.

Kleven H, Landais C, Søgaard J E, (2019). Children and Gender Inequality: Evidence from Denmark[J]. American Economic Journal: Applied Economics, 11(4): 181–209.

Knott E, Rao A H, Summers K, Teeger C, (2022). Interviews in the Social Sciences[J]. Nature Reviews Methods Primers, 2(1): 73.

Korinek A, (2023). Generative AI for Economic Research: Use Cases and Implications for Economists[J]. Journal of Economic Literature, 61(4): 1281–1317.

Lalive R, Zweimüller J, (2009). How Does Parental Leave Affect Fertility and Return to Work? Evidence from Two Natural Experiments[J]. The Quarterly Journal of Economics, 124(3): 1363–1402.

Landis J R, Koch G G, (1977). An Application of Hierarchical Kappa-type Statistics in the Assessment of Majority Agreement among Multiple Observers[J]. Biometrics, 33(2): 363–374.

Link S, Peichl A, Roth C, Wohlfart J, (2023). Attention to the Macroeconomy[R]. Social Science Research Network. https://papers.ssrn.com/abstract=4692410.

Lucas G M, Gratch J, King A, Morency L-P, (2014). It's Only a Computer: Virtual Humans Increase Willingness to Disclose[J]. Computers in Human Behavior, 37: 94–100.

Lucas G M, Rizzo A, Gratch J, Scherer S, Stratou G, et al. (2017). Reporting Mental Health Symptoms: Breaking Down Barriers to Care with Virtual Human Interviewers[J]. Frontiers in Robotics and AI, 4: 51.

Madrian B C, Shea D F, (2001). The Power of Suggestion: Inertia in 401 (K) Participation and Savings Behavior[J]. The Quarterly Journal of Economics, 116(4): 1149–1187.

Meng J, Wang H, Yang Y, Zhang M, (2026). Education Competition and Fertility Intention: Evidence from China's Private Tutoring Ban[J]. The Economic Journal, 136(676): 1504–1526.

Nass C, Moon Y, (2000). Machines and Mindlessness: Social Responses to Computers[J]. Journal of Social Issues, 56: 81–103.

Patton M Q, (2002). Two Decades of Developments in Qualitative Inquiry: A Personal, Experiential Perspective[J]. Qualitative Social Work, 1(3): 261–283.

Pickard M D, Roster C A, Chen Y, (2016). Revealing Sensitive Information in Personal Interviews: Is Self-disclosure Easier with Humans or Avatars and under What Conditions?[J]. Computers in Human Behavior, 65: 23–30.

Raute A, (2019). Can Financial Incentives Reduce the Baby Gap? Evidence from a Reform in Maternity Leave Benefits[J]. Journal of Public Economics, 169: 203–222.

Rubin H J, Rubin I S, (2011). Qualitative Interviewing: The Art of Hearing Data[M]. SAGE Publications, Inc.

Santurkar S, Durmus E, Ladhak F, Lee C, Liang P, et al. (2023). Whose Opinions Do Language Models Reflect?[C]// Proceedings of the 40th International Conference on Machine Learning: 29971–30004.

Shiller R J, (2017). Narrative Economics[J]. American Economic Review, 107(4): 967–1004.

Small M L, Calarco J M, (2022). Qualitative Literacy: A Guide to Evaluating Ethnographic and Interview Research[M]. University of California Press.

Spirling A, (2023). Why Open-source Generative AI Models are an Ethical Way Forward for Science[J]. Nature, 616(7957): 413–413.

Stantcheva S, (2021). Understanding Tax Policy: How Do People Reason?[J]. The Quarterly Journal of Economics, 136(4): 2309–2369.

Stantcheva S, (2022). Understanding of Trade[R]. National Bureau of Economic Research. https://www.nber.org/papers/w30040.

Stantcheva S, (2023). How to Run Surveys: A Guide to Creating Your Own Identifying Variation and Revealing the Invisible[J]. Annual Review of Economics, 15: 205–234.

Stefkovics Á, Sik E, (2022). What Drives Happiness? The Interviewer's Happiness[J]. Journal of Happiness Studies, 23(6): 2745–2762.

Thaler R H, Benartzi S, (2004). Save More Tomorrow™: Using Behavioral Economics to Increase Employee Saving[J]. Journal of Political Economy, 112(S1): S164-S187.

Törnberg P, (2023). ChatGPT-4 Outperforms Experts and Crowd Workers in Annotating Political Twitter Messages with Zero-Shot Learning[R]. arXiv. http://arxiv.org/abs/2304.06588.

Tranchero M, Brenninkmeijer C F, Murugan A, Nagaraj A, (2024). Theorizing with Large Language Models[R]. National Bureau of Economic Research. https://www.nber.org/papers/w33033.

Tversky A, Kahneman D, (1974). Judgment under Uncertainty: Heuristics and Biases[J]. Science, 185: 1124–1131.

Walther J B, (1996). Computer-mediated Communication: Impersonal, Interpersonal, and Hyperpersonal Interaction[J]. Communication Research, 23(1): 3–43.

Weidinger L, Uesato J, Rauh M, Griffin C, Huang P S, et al. (2022). Taxonomy of Risks Posed by Language Models[C]// Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency: 214–229.

Wu P Y, Nagler J, Tucker J A, Messing S, (2023). Large Language Models Can be Used to Estimate the Latent Positions of Politicians[R]. arXiv. http://arxiv.org/abs/2303.12057.

Ziems C, Held W, Shaikh O, Chen J, Zhang Z, et al. (2024). Can Large Language Models Transform Computational Social Science?[J]. Computational Linguistics, 50(1): 237–291.